

Consumer Finance Complaint Intelligence

Exploratory Data Analysis auf 10,27 Mio. CFPB-
Verbraucherbeschwerden

Datenbereinigung · Taxonomie-Harmonisierung · Quality Gates · Sensitivitätsanalyse

**Portfolio-Projekt
Modul 1**

2022-2025

Python · Polars · Pandas
SciPy · scikit-learn
Matplotlib · Plotly

1. Business-Frage und Analyseziel

Von öffentlichen Beschwerden zu einer kontrollierten Management-Sicht

Ausgangslage

- Beschwerdevolumen allein ist keine Qualitätskennzahl.
- Historische CFPB-Taxonomieänderungen können Trends künstlich verzerren.
- Aggregierte Portfolio-KPIs können von dominanten Segmenten geprägt werden.

Ziel


- Reproduzierbare Datenpipeline statt einmaliger Notebook-Analyse.
- Bereinigung und Harmonisierung vor Interpretation.
- Zeit-, Produkt-, Issue- und Response-Analyse mit Robustheitscheck.
- Management- und Consulting-Aussagen inklusive Interpretationsgrenzen.

Leitfrage

Welche Beschwerde- und Prozessmuster sind belastbar erkennbar - und welche verändern sich, sobald Datenqualität, Taxonomie und Segmentmix kontrolliert werden?

2. Datenbasis und technische Architektur

Offizielle CFPB-Daten · Multi-Millionen-Zeilen · reproduzierbare Verarbeitung



Engineering-Prinzipien

- Rohdaten bleiben unverändert.
- SHA-256-Provenienz für den lokalen Snapshot.
- Große CSV wird nicht vollständig im RAM materialisiert.
- Analyse-Logik liegt testbar in src/ - nicht im Notebook.

3. Datenqualität, Bereinigung und Taxonomie

Interpretation erst nach kontrollierter Aufbereitung

6

fehlende Source-Issue-Werte

0

unbehandelte Missing-Issues

1.335.250

Produktharmonisierungen

13,0 %

des Analysebestands

Source-Treue

- Originalfelder product und issue bleiben erhalten.
- Fehlendes issue bleibt im Source-Feld null.
- Analytisch wird nur zusätzlich harmonized_issue = "Issue not provided" gesetzt.

Taxonomie-Harmonisierung


- Historische Kategorien werden analytisch vergleichbar gemacht.
- taxonomy_version trennt alte und neue CFPB-Struktur.
- Vollständiger Source-to-Analytical-Audit wird als CSV veröffentlicht.

Data Quality Gate: passed = true

35 automatisierte Tests · Warning-as-error · Ruff · CI auf Python 3.11 und 3.13

4. Beschwerdevolumen wächst stark

2022 bis 2025: +580,2 % im veröffentlichten CFPB-Portfolio



Deskriptiver linearer Monatstrend: +10.511 Beschwerden/Monat · $R^2 = 0,877$ · keine Prognose

800.245

Beschwerden 2022

5.442.977


Beschwerden 2025

+580,2 %

Veränderung 2022→2025


5. Hohe Konzentration auf Credit Reporting

85,9 % des Gesamtbestands entfallen auf eine harmonisierte Produktgruppe



Top-Produkt

Credit reporting or other personal consumer reports: 8.824.129 Beschwerden




Top-Hotspot

Incorrect information on your report: 4.653.591 Beschwerden

6. Response Operations: Gesamtquote hoch, Segmente unterscheiden sich

Timely-Response-Rate als Screening-Signal - nicht als Unternehmensranking



99,6 %

Portfolio-Durchschnitt

84,8 %


Student Loan

Wichtig

Ohne Kunden-/Exposure-Nenner keine faire Performance-Rangliste.

7. Sensitivitätsanalyse: Der Produktmix verändert die Geschichte

Robustheitscheck des dominanten Credit-Reporting-Segments



Korrelation Beschwerden ↔ Narrative-Anteil: $r = -0,891$ gesamt vs. $-0,227$ ohne Credit Reporting

75,3 → 88,4 %

Credit-Reporting-Anteil

+220,3 %

Wachstum ohne Credit Reporting

91,2 %

Anteil an linearer Trendsteigung

8. Management- und Consulting-Implikationen

Was sich aus der EDA verantwortungsvoll ableiten lässt

Was die Daten zeigen

- Beschwerdevolumen wächst stark - auch außerhalb von Credit Reporting.
- Wenige Produkt-Issue-Kombinationen dominieren die öffentliche Beschwerdelandschaft.
- Aggregierte Portfolio-KPIs reagieren empfindlich auf Segmentmix.

Was als Nächstes sinnvoll wäre

- Hotspots für Root-Cause-Analysen priorisieren.
- Öffentliche Beschwerden mit internen Kunden-/Exposure-Daten verbinden.
- Segmentierte KPIs statt isolierter Portfolio-Aggregate verwenden.
- Consumer Narratives später mit NLP/GenAI untersuchen.

Responsible Interpretation

Beschwerdevolumen $\neq$ Qualität · Korrelation $\neq$ Kausalität · linearer Trend $\neq$ Forecast · Kompositionseffekt $\neq$ automatisch Simpson-Paradox

9. Fazit

EDA als reproduzierbarer Data-Intelligence-Workflow statt einmaliger Analyse

10,27 Mio.

reale CFPB-Beschwerden

35/35

automatisierte Tests

6

Portfolio-Visualisierungen

Projektbeitrag

- Große reale Finanzdaten effizient verarbeitet.
- Datenqualität und Taxonomiestabilität vor Interpretation kontrolliert.
- Statistische Ergebnisse durch Segment-Sensitivität hinterfragt.
- Technische Analyse in eine Management-/Consulting-Sicht übersetzt.

Kernaussage

Datenqualität, Taxonomie und Segmentstruktur müssen gemeinsam betrachtet werden, bevor Portfolio-KPIs fachlich interpretiert werden.

GitHub: [Maik-Huebner/consumer-finance-complaint-intelligence](https://github.com/Maik-Huebner/consumer-finance-complaint-intelligence)